

CURSO DE CIÊNCIA DA COMPUTAÇÃO – TCC		
(X) PRÉ-PROJETO	() PROJETO	ANO/SEMESTRE: 2023/1

MODELO DE APRENDIZADO DE MÁQUINA PARA ANÁLISE CINEMÁTICA DA MARCHA EM PACIENTES HEMIPLÉGICOS APÓS AVC

Eduarda Engels

Prof. Aurélio Faustino Hoppe – Orientador

1 INTRODUÇÃO

Segundo dados oficiais do Ministério da Saúde e das organizações mundiais de saúde, como a Organização Mundial de Saúde (OMS) e a Organização Pan-Americana da Saúde (OPAS), o Brasil apresenta a quarta maior taxa de mortalidade por Acidente Vascular Cerebral (AVC) entre os países da América Latina e Caribe. De acordo com o Ministério da Saúde (2022), em 2020, o AVC representava a segunda maior causa de morte do país, ficando atrás apenas de doenças do aparelho circulatório, tendo 43,9 óbitos por 100 mil habitantes.

De acordo com a Organização Mundial de Saúde (2019), o AVC afeta um ou mais vasos sanguíneos por um processo patológico que pode ocorrer pela falta de sangue nas veias, gerando isquemia, ou rompimento dos vasos sanguíneos causando hemorragia. Schmidt *et al.* (2019) ressaltam que a maior parte dos sobreviventes de AVC permanecem com sequelas, podendo ser física, comunicativa, sensitivas, funcionais, entre outras.

Segundo Luo *et al.* (2019), a sequela física mais comum ocasionada pelo AVC é a hemiplegia que é uma condição neurológica que se caracteriza pela paralisia de um dos lados do corpo, afetando significativamente a cinemática da marcha, como a simetria entre as pernas e a coordenação dos movimentos. Ainda segundo os autores, a análise cinemática da marcha em pacientes hemiplégicos fornece informações importantes sobre as alterações no padrão de marcha, como a redução no comprimento do passo, menor flexão do quadril e diminuição do tempo de apoio do membro afetado.

De acordo com o Ministério da Saúde (2022), o tratamento da hemiplegia geralmente envolve uma abordagem multidisciplinar, que inclui fisioterapia, terapia ocupacional e fonoaudiologia. O objetivo da terapia é maximizar a independência funcional do paciente, minimizando as limitações impostas pela paralisia. Uma das estratégias utilizadas na terapia é o treinamento oromotor precoce (desenvolvimento adequado da fala e da alimentação), que tem como objetivo normalizar as funções respiratória, de deglutição e de mastigação. Já as intervenções de reabilitação incluem exercícios específicos para melhorar a cinemática da marcha, com treinamento de passadas em esteira com suporte de peso corporal e terapia manual para aumentar o desempenho do movimento articular (MINISTERIO DA SAÚDE, 2022).

De acordo com Harris, Khoo e Demircan (2022), além da análise cinemática, existem diversas ferramentas de análise da hemiplegia que necessitam de equipamentos específicos e métodos de análise sofisticados, como sistemas de captura de movimento, plataformas de força e análise de imagem. Tais equipamentos exigem um alto investimento financeiro e podem não estar disponíveis em todos os centros de reabilitação, limitando o acesso e a avaliação da efetividade das intervenções terapêuticas. Nesse contexto, a utilização de técnicas de aprendizado de máquina apresenta-se como uma ferramenta promissora para o desenvolvimento de modelos preditivos que possam auxiliar na tomada de decisão clínica, possibilitando a identificação precoce de possíveis alterações na cinemática da marcha e o ajuste adequado do tratamento de acordo com as necessidades de cada paciente.

Diante deste cenário, surge a seguinte pergunta de pesquisa: "Como o uso de técnicas de aprendizado de máquina pode auxiliar na análise cinemática da marcha em pacientes hemiplégicos após um AVC?".

1.1 OBJETIVOS

O objetivo deste trabalho é criar um modelo de aprendizado de máquina de análise cinemática capaz de identificar anomalias na marcha em pacientes hemiplégicos pós AVC.

Os objetivos específicos são:

- identificar padrões complexos nas séries temporais de cinemática da marcha a partir de imagens;
- classificar automaticamente as fases da marcha em pacientes hemiplégicos e correlacioná-las com o nível de funcionalidade do paciente;
- avaliar a eficácia do modelo em relação à avaliação tradicional da cinemática da marcha;
- identificar possíveis limitações e desafios na utilização de técnicas de aprendizado de máquina no contexto de análise cinemática.

2 TRABALHOS CORRELATOS

Nesta seção serão apresentados trabalhos que possuem características semelhantes aos principais objetivos do estudo proposto. Na subseção 2.1 é detalhado o trabalho de Benjinariu *et al.* (2021), ao qual desenvolveram uma aplicação para estimar o ângulo de flexão do joelho a fim de detectar anomalias na marcha humana por meio de redes neurais. A subseção 2.2 descreve o trabalho de Lu *et al.* (2019), que busca medir o nível de marcha de pacientes com hemiplegia por meio de árvore de decisão. Por fim, a subseção 2.3 apresenta o trabalho de Slijepcevic *et al.* (2021), que utilizam o método *Layer-wise Relevance Propagation* (LRP), tendo como objetivo aumentar a compreensão dos resultados dos classificadores de aprendizado de máquina em relação a análise automatizada da marcha.

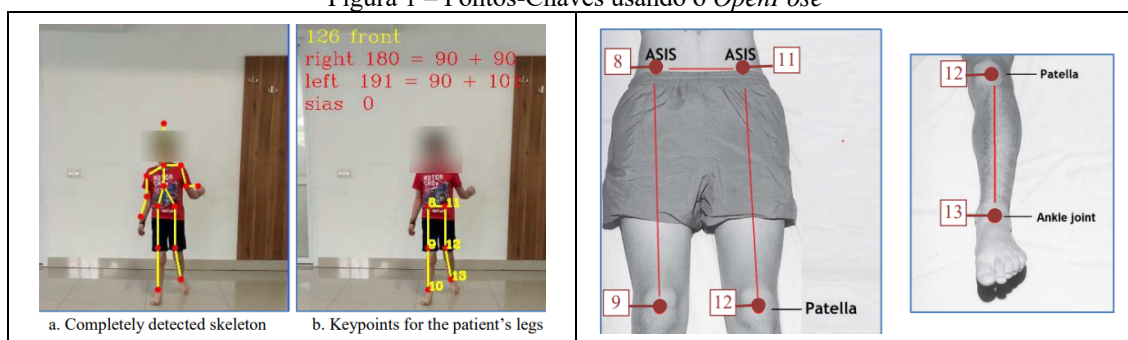
2.1 IMAGE PROCESSING FOR THE REHABILITATION ASSESSMENT OF LOCOMOTION INJURIES AND POST STROKE DISABILITIES

Benjinariu *et al.* (2021) utilizam a análise de movimento para auxiliar na reabilitação locomotora, com foco em tratamento de Acidente Vascular Cerebral (AVC), nos membros inferiores do corpo. Os autores aplicaram métodos de *Machine Learning* (ML) para extração e análise da marcha. Os atribuídos utilizados foram inerciais (acelerações), posturais (ângulos formados por segmento do corpo humano) ou espaço-temporal (comprimento da passada, frequência e variabilidade da passada)

Benjinariu *et al.* (2021) utilizaram como base de dados vídeos adquiridos de pacientes que estão se recuperando de fraturas nos membros inferiores, aos quais foram filmados em um plano frontal e sagital com uma taxa média de 30 segundos. Os autores extraíram os ângulos e a velocidade de diferentes articulações em diferentes ações como caminhar, trotar e correr. Para a classificação, utilizam o classificador *Random Forest* implementado na linguagem de programação C++.

De acordo com Benjinariu *et al.* (2021), a *Human Pose Estimation* (HPE) consiste em determinar a posição do corpo humano utilizando imagens, tarefa desafiadora, que pode ser abordada por meio de diversos métodos, que vão desde o uso de sensores até marcadores. Os modelos baseados em *Convolutional Neural Network* (CNN) utilizam esqueletos, contornos e volumes para modelar o corpo humano. No processo de detecção, um conjunto de pontos anatômicos-chave é calculado para cada indivíduo na imagem, utilizando-se o OpenPose, que processa o vídeo quadro a quadro, resultando em uma lista de pontos-chave especificados por coordenadas 2D. Segundo os autores, isso permite identificar partes esquerda e direita do corpo, bem como se ele está sendo visto de frente ou de costas. A Figura 1 exemplifica o processo de redução do número de pontos e a posição correta das pernas por meio dos pontos-chave.

Figura 1 – Pontos-Chaves usando o *OpenPose*




Fonte: Benjinariu *et al.* (2021).

Segundo Benjinariu *et al.* (2021), as posições dos pontos-chave definem a condição patológica da pessoa, ao qual, realiza-se a análise a partir dos ângulos dos segmentos das pernas. Os autores também destacam que o ângulo do quadril entre Espinha Ilíaca AnteroSuperior (EIAS) e a linha média da coxa deve ser de 90°, assim como, a linha média da coxa e do tornozelo também precisam estar alinhados com o joelho na posição ortostática (quando estiver em pé). Outra constatação é que, durante o caminhar, os ângulos do joelho diminuem, e, se chegarem a 10° de variação, para dentro ou fora, há indícios de um caso patológico.

De acordo com Benjinariu *et al.* (2021), nem todos os quadros foram considerados durante a implementação do OpenPose, pois nem sempre os pontos podiam ser identificados ou a silhueta do paciente era visível. Analisando os ângulos obtidos, o valor máximo do ângulo no joelho direito é de 192° e no esquerdo é de 194°, indicando uma situação patológica pois o joelho se move para fora enquanto caminha. O valor médio dos ângulos está dentro do limite de 10° na variação interna. Os valores de ângulos na linha EIAS trouxeram valores altos como 30° por conta do posicionamento dos pontos na detecção automática. No entanto, a variação do ângulo EIAS nas imagens dos pacientes é grande. A Figura 2 apresenta a evolução dos ângulos dos *frames* 425 a 453, no qual são inferiores a 180°, apontando que ambos os joelhos estão para fora.

Figura 2 – Variação angular dos joelhos nos quadros 425-453



Fonte: Benjinariu *et al.* (2021).

Benjinariu *et al.* (2021) afirmam que a pesquisa ainda está em andamento e os resultados obtidos para avaliação de reabilitação da locomoção são promissores. Para as próximas atualizações, pretendem aumentar o número de sequências de vídeos utilizados e incluir gravações com pacientes reabilitados ou saudáveis para comparação de avaliação automática. Também querem rever a detecção de pontos-chave aplicando outros métodos de HPE.

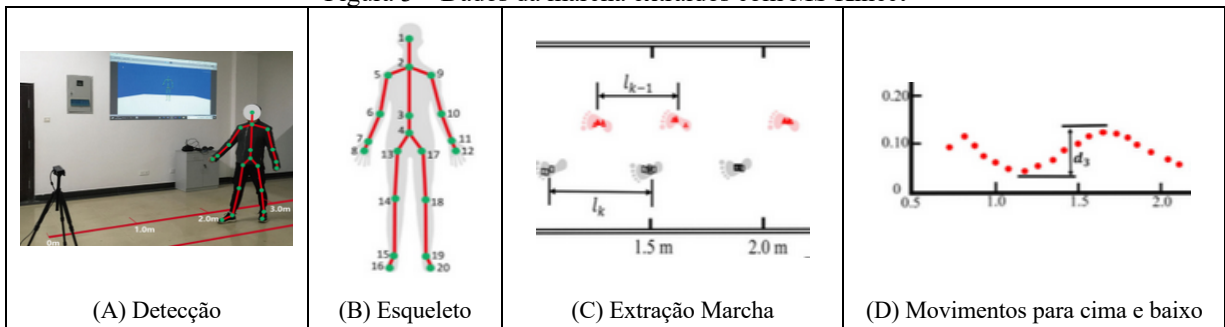
2.2 RANDOM FOREST-BASED CLASSIFICATION AND ANALYSIS OF HEMIPLEGIA GAIT USING LOW-COST DEPTH CAMERAS

Luo *et al.* (2019) utilizaram o sensor Microsoft Kinect para capturar a marcha no espaço-tempo e a cinemática articular a partir de configurações simples a fim de investigar o potencial da ferramenta em realizar análise da marcha hemiplegia. Os autores coletaram os dados no Departamento de Medicina de Reabilitação do Hospital Popular de Jiangxi.

Segundo Luo *et al.* (2019), foram recrutados 60 indivíduos, sendo 40 saudáveis e 20 pacientes com hemiplegia, que tiveram que realizar o movimento padrão de andar em linha reta 4 metros em frente ao sensor Kinect, repetindo este processo 9 vezes. Os dados extraídos para compor as características espaço-tempo foram a velocidade e o comprimento da passada

Luo *et al.* (2019) calcularam o ponto médio das juntas em relação as coordenadas do planar direito e esquerdo. A partir disso, segundo os autores, torna-se possível calcular a distância euclidiana entre os dois para estimar o comprimento inicial. Na Figura 3 item (A) pode-se observar a detecção do participante em tempo real, no item (B) o esqueleto com as juntas enumeradas, no item (C), a marcha extraída durante a caminhada e, por fim, no item (D) a extração de esquerda e direita com movimentos para cima e para baixo do centro de massa.

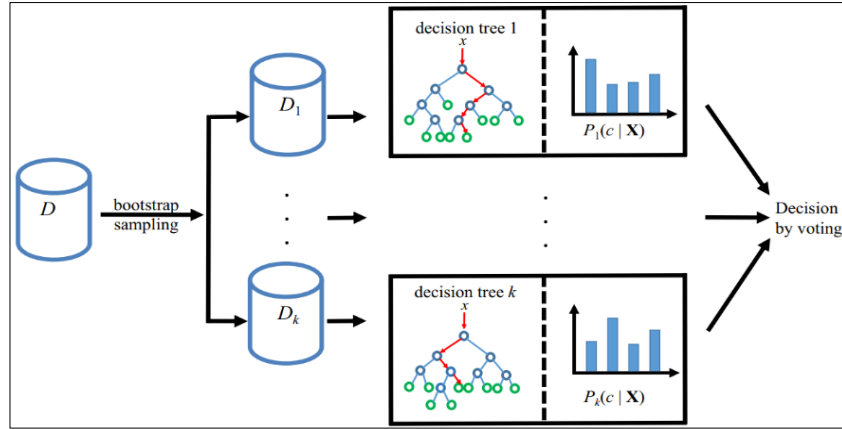
Figura 3 – Dados da marcha extraídos com MS Kinect



Fonte: Luo *et al.* (2019).

Segundo Luo *et al.* (2019), a característica chave para realizar a análise cinemática é o centro da massa do indivíduo. Para isso, eles utilizaram um método de segmentação corporal que corta o corpo humano em pequenos segmentos. Posteriormente, na linguagem de programação Python, aplicou-se o *Random Forest* (RF) para realizar a classificação das combinações. Ainda segundo os autores, a partir de um conjunto de dados de treinamento aleatório, utiliza-se o Índice de Gini para definir as características ótimas para efetuar a divisão dos participantes. A Figura 4 exemplifica a aplicação de múltiplas árvores de decisão, no qual D denota o conjunto de dados de entrada.


Figura 4 – Método de classificação *Random Forest*



Fonte: Luo *et al.* (2019).

Luo *et al.* (2019) utilizaram um número maior de amostras de pessoas saudáveis, tendo em vista sua proporção em relação a população de indivíduos sem hemiplegia. Para estabelecer o melhor método de classificação, os autores utilizaram o *Receiver Operator Characteristic Curve* (ROC), no qual cada ponto corresponde a um par de *False-Positive Rate* (FPR) ou *True-Positive Rate* (TPR). Portanto, a curva de ROC deveria ter o TPR mais alto e o FPR mais baixo, ou seja, quanto mais próximo do canto superior esquerdo a curva estiver, melhor será a classificação, conforme ilustra a Figura 5.

Figura 5 – ROC comparando os métodos de classificação



Fonte: Luo *et al.* (2019).

Luo *et al.* (2019) comparam os resultados da classificação do RF em relação às redes *Bayesianas* e a *Support Vector Machine* (SVM). Dentre eles, o RF obteve, em média, 90% de precisão entre todas as combinações de características, pois as árvores de decisão são independentes entre si. Os autores também afirmam que pretendem utilizar mais o MS Kinect para capturar as características das passadas e o ângulo do pé para análise da marcha.

2.3 EXPLAINING MACHINE LEARNING MODELS FOR CLINICAL GAIT ANALYSIS


Segundo Slijepcevic *et al.* (2021), a Análise Clínica da Marcha (ACM) se concentra em analisar e descrever quantitativamente aspectos cinemáticos (ângulos articulares), cinéticos (forças de reação do solo e momentos articulares) e musculares (eletromiografia). Neste contexto, os autores exploraram métodos de *Explainable Artificial Intelligence* (XAI) para identificar como os modelos de ML produzem suas previsões por meio do *Layer-wise Relevance Propagation* (LRP), tendo como objetivo aumentar a transparência na classificação método automatizada clínica da marcha baseada em séries temporais.

Slijepcevic *et al.* (2021) optaram pelos classificadores *Support Vector Machine* (SVM), *Multilayer Perceptron* (MLP) e *Convolutional Neural Network* (CNN) como abordagens de ML para comparar a precisão e os padrões de relevância das entradas. O SVM foi treinado utilizando o método de otimização quadrática. Para a MLP, utilizou-se três camadas não lineares e conectadas com a função SoftMax na camada de saída. Já no modelo CNN, aplicou-se três camadas *convolucionais* consecutivas, sendo mapeado por um vetor com mais de 2 mil dimensões. Segundo os autores, os modelos MLP e CNN foram treinados usando o gradiente descendente estocástico e a média absoluta com os pesos sendo iniciados aleatoriamente.

Slijepcevic *et al.* (2021) estruturam os treinos dos modelos de classificação de acordo com as etapas presentes no fluxo de classificação da Figura 6. Inicialmente, obtém-se os dados de entrada através do *Ground Reaction Forces* (GRFs) de ambas as pernas. No item (B), realiza-se a classificação com base nas forças tridimensionais de GRFs. Posteriormente, no item (C), utiliza-se as pontuações relevantes referentes ao espectro

do sinal de entrada através da LRP. Por fim, nos itens (D) e (E) busca-se explicar os resultados de forma estatística ou na perspectiva clínica.


Figura 6 – Fluxo de classificação automatizada de marcha



Fonte: Slijepcevic *et al.* (2021).

Slijepcevic *et al.* (2021) utilizaram dados de 132 pacientes com distúrbios da marcha e de 62 saudáveis, de ambos os gêneros e com diferentes características físicas, para medir as GRFs. Segundo os autores, o conjunto de dados incluiu três classes de distúrbios ortopédicos da marcha associados ao quadril, joelho e tornozelo. Para capturar as GRFs tridimensionais, foram utilizados quatro componentes: força horizontal, força médio-lateral, força anteroposterior horizontal e força vertical, gerando um vetor de entrada com 1x606 dimensões para cada tentativa de marcha. No entanto, segundo Slijepcevic *et al.* (2021), os resultados indicaram uma diferença mínima entre os classificadores. A Figura 7 apresenta a acurácia obtida pelos modelos CNN, SVM e MLP.

Figura 7 – Accuracy dos modelos ML



Fonte: Slijepcevic *et al.* (2021).

De acordo com Slijepcevic *et al.* (2021), o LRP consegue determinar onde a previsão está fundamentada, porém não explica o motivo para esses padrões. Além disso, segundo os autores, a utilização dele é apenas indicada se o método de classificação alcançar conclusões significativas, pois ao analisar um modelo não confiável, pode resultar em ruídos e padrões instáveis. Além disso, Slijepcevic *et al.* (2021) também observaram que a normalização dos dados de entrada acaba sendo um fator importante para o ML, pois caso os intervalos entre os valores forem divergentes afeta negativamente a previsão. Por fim, os autores ressaltam que os métodos de XAI, para explicar as previsões de modelos ML, são promissores e podem ajudar na justificativa das classificações automáticas de CGA.

3 PROPOSTA DE MODELO

Esta seção apresenta a justificativa para o desenvolvimento deste trabalho, que tem como objetivo propor um modelo de aprendizado de máquina para análise cinemática da marcha em pacientes com AVC. A metodologia adotada para o desenvolvimento do modelo será detalhada, bem como os requisitos necessários para a sua implementação, além disso, serão apresentados os principais assuntos e fontes bibliográficas que irão fundamentar o estudo proposto.

3.1 JUSTIFICATIVA

No Quadro 1 é possível observar as principais características de cada trabalho correlato apresentado, onde as colunas são cada trabalho e as linhas as características, com elas podemos entender como será solucionado os problemas propostos por este trabalho.

Quadro 1 – Comparativo dos trabalhos correlatos

Trabalhos Correlatos Características	Benjinariu <i>et al.</i> (2021)	Luo <i>et al.</i> (2019)	Slijepcevic <i>et al.</i> (2021)
Patologia de identificação	Acidente Vascular Cerebral (AVC)	Hemiplegia	Acidente Vascular Cerebral (AVC)
Objetivo	Identificar anormalidades na marcha humana	Identificar anormalidades na marcha humana	Esclarecer as previsões de modelos de classificação
Membros da avaliação	Inferiores	Inferiores	Inferiores
Técnica de análise utilizada	Aprendizado de máquina	Aprendizado de máquina	Aprendizado de máquina e Inteligência artificial explicável
	HPE	Pontos do esqueleto	LRP
Número de pacientes avaliados	Não mencionado	60	194
Taxa de acerto	Não mencionado	>90%	Não mencionado
Dispositivo para captura de dados	<i>Smartphone (video)</i>	MS Kinect	Plataformas de força (GRFs)
Linguagem de programação	C++	Não mencionado	Python

Fonte: elaborado pela autora.

A partir do Quadro 1 pode-se observar que todos os autores utilizam modelos de avaliação dos membros inferiores para a identificação de anomalias da marcha. Destaca-se o trabalho de Slijepcevic *et al.* (2021) ao qual realizaram uma comparação entre os modelos de classificação de marcha (SVM, MLP e CNN). Além disso, também utilizaram inteligência artificial explicável (método *Layer-wise Relevance Propagation*) para poder justificar os resultados das previsões e aprimorar a classificação clínica automatizada da marcha humana em pacientes com AVC. Nos testes, os autores utilizaram dados de GRFs de 194 pacientes. Por fim, Slijepcevic *et al.* (2021) concluem que método o LRP consegue determinar onde a previsão está fundamentada, porém não explica o motivo para esses padrões.

Benjinariu *et al.* (2021) utilizaram redes neurais para estimar o ângulo de flexão do joelho, assim como detectar anomalias na marcha humana de pacientes que sofreram AVC. Para isso, os autores utilizaram a biblioteca do OpenPose, implementado em C++, que permite detectar a parte esquerda e direita do corpo, assim como a direção, se o corpo está sendo visto de frente ou de trás. A captura dos dados foi realizada através de um *smartphone* e os resultados foram apresentados na forma de um gráfico que demonstra a variação angular dos joelhos que são extraídos a partir da posição de pontos-chave para indicar a condição patológica da pessoa. Por fim, os autores apontam que, apesar da pesquisa estar em andamento, os resultados são promissores e que, ao longo do tempo, serão utilizados mais vídeos para aperfeiçoar o modelo.

Lu *et al.* (2019) tinham como intuito identificar anomalias, assim como estabelecer o nível de marcha em pacientes com hemiplegia por meio de uma árvore de decisão e um conjunto de entrada aleatório. Os autores utilizaram o sensor de profundidade Microsoft Kinect (MS Kinect) para detectar o movimento em tempo real. A partir disso, construíram uma base de dados com as características de 60 indivíduos. Posteriormente, Lu *et al.* (2019) aplicaram um método de segmentação corporal para subdividir o corpo humano em pequenos segmentos, aos quais foram utilizados como entrada pelos algoritmos *Random Forest* (RF), redes *Baysianas* e a *Support Vector Machine* (SVM). Segundo os autores, a RF apresentou a melhor precisão, cerca de 90%.

Com base no cenário descrito acima, pode-se observar que os trabalhos utilizam diferentes métodos de análise para identificar anomalias na marcha humana. Contudo, percebe-se a necessidade do desenvolvimento de um modelo mais adequado para analisar as informações cinemáticas dos pacientes, considerando as limitações de equipamento de captura e da quantidade e especificidade da população estudada. Diante disso, o diferencial do trabalho proposto encontra-se justamente no desenvolvimento de um modelo de aprendizado de máquina específico para a análise cinemática da marcha em pacientes hemiplégicos após AVC. Ao qual, poderá trazer uma contribuição significativa para a área da reabilitação, auxiliando na elaboração de terapias mais eficientes e personalizadas para os pacientes, além de poder ser aplicado em outras populações com problemas de locomoção.

Tecnologicamente, o uso do modelo de aprendizado de máquina permite uma análise mais objetiva e contínua do progresso do paciente. Com isso, espera-se facilitar o trabalho do profissional de saúde, possibilitando ajustes mais precisos e individualizados nas intervenções de reabilitação assim como, reduzindo o tempo de diagnóstico e tratamento. Contudo, impactando significativamente na qualidade de vida dos pacientes, bem como na efetividade dos tratamentos atualmente oferecidos.

3.2 REQUISITOS PRINCIPAIS DO PROBLEMA A SER TRABALHADO

O trabalho proposto deverá contemplar os seguintes Requisitos Funcionais (RF) e Requisitos Não Funcionais (RNF):

- permitir o cadastro de pacientes (RF);
- permitir ao usuário capturar ou importar vídeos dos membros inferiores do corpo (RF);
- realizar o realce e melhoramento de ruídos, distorções e problemas de iluminação utilizando técnicas de processamento de imagens (RF);
- efetuar a análise cinemática a partir dos membros inferiores utilizando redes neurais convolucionais e/ou recorrentes (RF);
- estabelecer o nível de funcionalidade do paciente a partir do movimento corporal (RF);
- manter o usuário informado sobre a situação do processamento das imagens/vídeos (RF);
- aprimorar o modelo a partir de novos vídeos cadastros pelos usuários (RNF);
- utilizar as bibliotecas OpenCV para o processamento de imagens e o Keras ou Tensorflow para a construção da rede neural artificial (RNF).

3.3 METODOLOGIA

O trabalho será desenvolvido observando as seguintes etapas:

- levantamento bibliográfico: estudar os assuntos relacionados à acidente vascular cerebral, análise cinemática, aprendizado de máquina e trabalhos correlatos;
- acompanhamento clínico: acompanhar atendimentos realizados no Centro de Reabilitação da Furb II, com pacientes que sofreram AVC, para entendimento do problema e constatação de necessidades;
- submissão ao conselho de ética: escrita e cadastro do trabalho na plataforma Brasil e submissão para o conselho de ética da FURB. Ressaltando que em cada experimento será solicitado aos pacientes a assinatura do Termo de Consentimento Livre e Esclarecido (TCLE);
- coleta de dados: coleta de dados de cinemática da marcha em pacientes hemiplégicos após AVC, realizando a gravação de vídeos;
- definição de algoritmos para extrair a cinemática da marcha: pesquisar métodos de processamento de imagens para extrair/estabelecer medidas a partir de imagens/vídeos;
- definição de algoritmos para classificação das fases da marcha: pesquisar as técnicas de aprendizado de máquina (convolucionais ou recorrentes) para classificar automaticamente as fases da marcha em pacientes hemiplégicos e correlacioná-las com o nível de funcionalidade do paciente;
- análise temporal: realização de análises temporais para avaliar a variação temporal dos parâmetros de cinemática da marcha e identificar mudanças ao longo do tempo;
- desenvolvimento do modelo: a partir dos itens (g), (h) e (i), realizar a implementação da análise cinemática utilizando a biblioteca OpenCV, a linguagem de programação Python e as bibliotecas Keras e Tensorflow;
- testes do modelo: paralelamente à implementação, realizar testes com base nos vídeos obtidos para verificar a eficiência e assertividade do modelo elaborado utilizando a validação cruzada assim como a comprovação dos resultados a partir de um grupo de pacientes hemiplégicos após AVC em conjunto com profissionais da saúde.

As etapas serão realizadas nos períodos relacionados no Quadro 2.

Quadro 2 – Cronograma de atividades a serem realizadas

etapas / quinzenas	2023									
	jul.		ago.		set.		out.		nov.	
	1	2	1	2	1	2	1	2	1	2
levantamento bibliográfico										
acompanhamento clínico										
submissão ao conselho de ética										
coleta de dados										
definição de algoritmos para extrair a cinemática da marcha										
definição de algoritmos para classificação das fases da marcha										
análise temporal										
desenvolvimento do modelo										
testes do modelo										

Fonte: elaborado pela autora.

4 REVISÃO BIBLIOGRÁFICA

Nesta seção serão apresentados os principais conceitos que fundamentam o estudo proposto. Serão abordados de forma breve o Acidente Vascular Cerebral (AVC), considerando suas características e consequências, além da análise cinemática da marcha, que consiste na técnica de avaliação da locomoção humana, permitindo uma avaliação mais precisa das alterações motoras decorrentes do AVC. Por fim, conceitua-se aprendizado de máquina e suas principais técnicas.

De acordo com o National Institutes of Health (2023), o AVC ocorre quando o fluxo sanguíneo de uma área do cérebro é interrompido. Sendo causado por um coágulo sanguíneo, identificado como isquêmico, ou por um vaso sanguíneo rompido que é denominado de hemorrágico. Essa condição pode levar a danos cerebrais permanentes ou a morte caso não seja tratado imediatamente. O diagnóstico é feito com base nos sintomas e em exames de imagem, como tomografias computadorizadas ou ressonância magnética do cérebro (SECRETARIA DE ATENÇÃO À SAÚDE, 2022).

Segundo a Secretaria de atenção à saúde (2022), uma das consequências do AVC é a hemiplegia, uma condição que paralisa um lado do corpo humano e pode afetar a marcha do indivíduo. A análise cinemática da marcha é uma ferramenta importante para a avaliação e tratamento da hemiplegia, permite identificar alterações e anormalidades nas passadas. Normalmente, são utilizados equipamentos de alta tecnologia como as câmeras de captura de movimento e sensores que permitem avaliar o comprimento do passo, contato com o solo e a distribuição do peso, além de outros fatores que ajudam a identificar possíveis problemas (SECRETARIA DE ATENÇÃO À SAÚDE, 2022).

Segundo Kim *et al.* (2018), identificar anormalidades na marcha é fundamental para o diagnóstico e tratamento de doenças e lesões que afetam o caminhar de uma pessoa, como o acidente vascular cerebral, lesões medulares, doenças neuromusculares e ortopédicas. Além disso, os autores também afirmam que ao utilizar a análise cinemática da marcha para avaliar os efeitos de um programa de treinamento em pacientes com hemiplegia pode-se reduzir e alcançar resultados melhores na simetria da marcha em menos tempo.

De acordo com Alpaydin (2012), *Machine Learning* (ML) é um ramo da inteligência artificial que utiliza técnicas computacionais para permitir que um sistema aprenda e melhore com a experiência. Segundo o autor, ML é uma abordagem de modelagem de dados que automatiza a construção de modelos analíticos. Entre suas principais características, destacam-se (I) o aprendizado automático, que aprendem a partir dos dados e se ajusta para melhoria de desempenho, (II) a generalização, ou seja, fazer previsões e classificações em novos dados que não foram utilizados no treinamento, e (III) a adaptabilidade, os modelos podem se adaptar as situações melhorando sua resposta com o tempo.

Alpaydin (2012) ainda destaca que o uso de cada arquitetura ou algoritmo de ML depende do tipo do problema a ser resolvido e as características dos dados existentes. Dentre as principais técnicas, encontram a Árvore de Decisão, o *Support Vector Machine* (SVM) e os algoritmos de clusterização. A árvore de decisão utiliza um modelo de estrutura hierárquica para tomar decisões com bases nos dados, dividindo em subconjuntos menores e regras para a classificação dos dados. O SVM, separa as classes dos dados em um hiperplano. Já os algoritmos de agrupamento, utilizam características semelhantes para dividir um conjunto de dados em *clusters* (ALPAYDIN, 2012).

Segundo Alpaydin (2012), dentre os algoritmos de ML, destacam-se a redes neurais, inspirada no cérebro humano, que consistem em redes interconectadas que aprendem a partir dos dados. Já a *Convolutional Neural Network* (CNN) é capaz de extrair características relevantes das imagens, como bordas e texturas para a classificação ou reconhecimento de objetos. Por outro lado, as redes neurais recorrentes são usadas para técnicas de processamentos de sequência de dados, possuindo conexões que permitem que as informações sejam propagadas de uma etapa da sequência para a próxima, permitindo a captura de informações contextuais e para realizar previsões.

REFERÊNCIAS

ALPAYDIN, Ethem. **Introduction to Machine Learning**. Cambridge: Cambridge University Press (CUP), 2012.

BENJINARIU, Silviu-Ioan *et al.* **Image Processing for the Rehabilitation Assessment of Locomotion Injuries and Post Stroke Disabilities**. 2021 International Conference On E-Health And Bioengineering (Ehb), Iasi, Romania, p. 2-5, 2021.

HARRIS, Elsa J.; KHOO, I-Hung; DEMIRCAN, Emel. A Survey of Human Gait-Based Artificial Intelligence Applications. **Frontiers In Robotics And AI**, Long Beach, v. 8, p. 1-28, jan. 2022. Frontiers Media SA.

KIM, JH. *et al.* Effect of gait training with functional electrical stimulation on gait capacity in stroke survivors with chronic hemiplegia: a randomized controlled trial. **Annals of Rehabilitation Medicine**, v. 42, n. 4, p. 560-571, 2018.

LUO, Guoliang. *et al.* Random forest-based classification and analysis of hemiplegia gait using low-cost depth cameras. **Medical & Biological Engineering & Computing**, [S.l.], v. 58, n. 2, p. 373-382, 18 dez. 2019. Springer Science and Business Media LLC.

NATIONAL INSTITUTES OF HEALTH. **Stroke**: what is a stroke? National Institute Of Neurological Disorders And Stroke, Rockville. Disponível em: <https://www.ninds.nih.gov/health-information/disorders/stroke>. Acesso em: 07 maio 2023.

ORGANIZAÇÃO MUNDIAL DE SAÚDE. **Global Health Estimates 2019**: Deaths by Cause, Age, Sex, by Country and by Region, 2000-2019. Disponível em: <https://www.who.int/data/gho/data/themes/mortality-and-global-health-estimates/gh-leading-causes-of-death>. Acesso em: 07 maio 2023.

SCHMIDT, Michelle Hillig. *et al.* **Acidente Vascular Cerebral e diferentes limitações**: uma análise interdisciplinar. Arquivos de Ciências da Saúde da Unipar, [S.l.], v. 23, n. 2, p. 1-2, 16 maio 2019. Universidade Paranaense.

SECRETARIA DE ATENÇÃO À SAÚDE. **Diretrizes de Atenção à Reabilitação de Pessoa com Acidente Vascular Cerebral**. Ministério da Saúde, Brasília - DF, p. 3-74. Disponível em: <https://www.gov.br/saude/pt-br/assuntos/saude-de-a-a-z/s/saude-da-pessoa-com-deficiencia/publicacoes/diretrizes-de-atencao-a-reabilitacao-da-pessoa-com-acidente-vascular-cerebral.pdf/view>. Acesso em: 07 maio 2023.

SLIJEPCEVIC, Djordje *et al.* Explaining Machine Learning Models for Clinical Gait Analysis. **ACM Transactions On Computing For Healthcare**, New York, v. 3, n. 2, p. 1-27. Association for Computing Machinery (ACM).