

CURSO DE CIÊNCIA DA COMPUTAÇÃO – TCC		
() PRÉ-PROJETO	(X) PROJETO	ANO/SEMESTRE: 2023/1

PROTÓTIPO PARA A CLASSIFICAÇÃO DE ESPÉCIES DE SERPENTES POR MEIO DE TÉCNICAS DE APRENDIZADO DE MÁQUINA E VISÃO COMPUTACIONAL

Camila Carolina Bowens

Prof. Andreza Sartori – Orientadora

Prof. Luís Olímpio Menta Giasson – Coorientador

1 INTRODUÇÃO

A Organização Mundial de Saúde (2021), estima que 5,4 milhões de pessoas no mundo são picadas por serpentes todos os anos, ocasionando a morte de 81.000 a 138.000 pessoas, a qual, cerca do triplo deste número, ficam com sequelas permanentes. Picadas de cobras venenosas podem causar emergências médicas agudas, envolvendo paralisia grave, distúrbios hemorrágicos, insuficiência renal irreversível e destruição grave de tecidos locais causando incapacidade permanente, em casos mais graves a amputação de membros.

Apesar de devastadores, os efeitos das picadas de serpentes podem ser revertidos se tratados com urgência utilizando soro antídoto. Estes antídotos são formados por anticorpos, com o objetivo de neutralizar o veneno que se encontra no sangue e nos tecidos da pessoa que sofreu a picada. Segundo o Instituto Butantan (2023), os soros antídotos para as picadas de serpentes são distribuídos na rede pública de saúde e são divididos em categorias por famílias e gênero de espécies de serpente, fazendo assim necessário a identificação da espécie que atacou o paciente para que seja realizado o atendimento correto.

Para realizar a correta identificação de espécies de serpentes, assim como qualquer espécie animal, são utilizadas chaves taxonômicas, uma ferramenta de identificação e categorização de espécies a partir de suas características morfológicas. As características morfológicas mais utilizadas na identificação das espécies de serpentes, conforme Waltrick e Giasson (2021), são o formato da cabeça, ponta da cauda e padrão de escamas ao longo do corpo do animal. Mesmo com auxílio de chaves taxonômicas, essa identificação ainda pode ser desafiadora, considerando que é possível existir espécies com características morfológicas semelhantes na mesma região, como é o caso das espécies *Oxyrhopus clathratus* conhecida como falsa coral, incapaz de inocular veneno, e a *Micrurus corallinus* conhecida como coral verdadeira, espécie venenosa, ambas encontradas na região do Vale do Itajaí, em Santa Catarina.

No estado de Santa Catarina, existem 84 espécies de serpentes, sendo 11 delas serpentes venenosas com acidentes registrados nas interações com seres humanos e animais domésticos. Por este motivo, o acesso à informação é vital para a prevenção de acidentes, desde o conhecimento das espécies associadas, como os procedimentos de segurança em casos de acidentes. De fato, uma das consequências da desinformação, reconhecida pela comunidade de biólogos como um problema, é a matança indiscriminada de serpentes proveniente do medo das pessoas, o que contribui para a degradação da biodiversidade no estado. Seja para a segurança das pessoas, como para a conservação de espécies, a educação a respeito das espécies de serpentes e a capacidade de reconhecê-las é crucial (OLIVEIRA. *et al.*, 2020).

Nos últimos anos o uso de técnicas de Aprendizado de Máquina e Visão Computacional no desenvolvimento de ferramentas para a identificação de animais tem crescido rapidamente para diversas finalidades. Estes, são aplicados em áreas como na indústria pecuária, na rastreabilidade de produtos de origem animal e análise de comportamento dos animais (ESTEVAM, 2019), ou, nos projetos de monitoramento e conservação de espécies, onde a identificação por câmeras dispensa a necessidade de captura de animais silvestres (WILDLIFE AI, 2021).

Diante do apresentado, este trabalho tem como objetivo o desenvolvimento de um protótipo para realizar a classificação de algumas das espécies de serpentes mais comuns da região do Vale do Itajaí, em Santa Catarina utilizando técnicas de visão computacional e aprendizado de máquina.

1.1 OBJETIVOS

O objetivo deste trabalho é disponibilizar um protótipo para realizar a classificação de espécies de serpentes mais comuns do Vale do Itajaí a partir de imagens utilizando técnicas de visão computacional e aprendizado de máquina.

Os objetivos específicos são:

- compor uma base de dados de imagens de espécies serpentes encontradas na região do Vale do Itajaí e categorizá-las por espécie e características taxonômicas;
- classificar automaticamente as serpentes por meio de suas características morfológicas.
- avaliar a eficácia dos modelos aplicados para definir o melhor para classificação de espécies de serpentes;
- identificar possíveis limitações na aplicação de técnicas de visão computacional e aprendizado de máquina na identificação automática de serpentes.

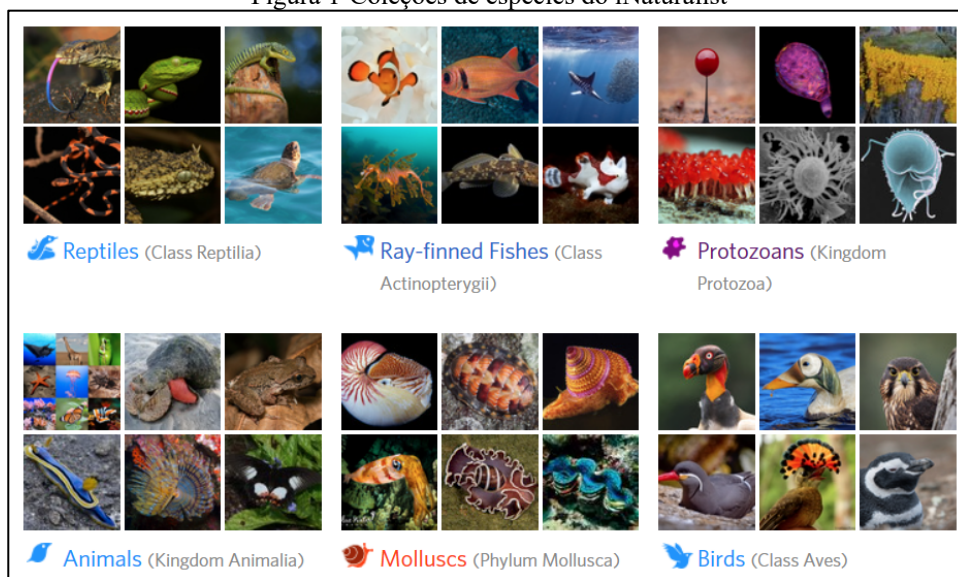
2 TRABALHOS CORRELATOS

Nesta seção serão apresentados os trabalhos correlatos. O primeiro é uma plataforma online para identificar e catalogar espécies de seres vivos de todo o globo a partir de imagens, vídeos e sons (INATURALIST, 2023a). Vasmatkar *et al.* (2020), desenvolveram uma ferramenta desenvolvida para o reconhecimento de serpentes através de suas características taxonômicas utilizando Redes Neurais Convolucionais. Por fim, Rajabizadeh e Rezghi, (2021) apresentam um estudo comparativo dos diferentes métodos de aprendizado de máquina, avaliando sua performance na identificação de serpentes, comparando Redes Neurais Artificiais (RNA) com algoritmos de aprendizado de máquina menos complexos, como Máquinas de Vetores de Suporte e K-vizinhos mais próximos.

2.1 INATURALIST

O iNaturalist (2023a) é uma ferramenta criada a partir de uma iniciativa conjunta da *California Academy of Sciences* e da *National Geographic Society*. A ferramenta possibilita a identificação de espécies de animais, plantas e células através de imagens, vídeos e sons, com o objetivo de mapear a biodiversidade de todo o globo. A Figura 1 apresenta algumas das coleções de imagens cadastradas na ferramenta. Além disso, a ferramenta conta com uma comunidade de cientistas e naturalistas para avaliar a qualidade científica dos dados coletados.

Figura 1-Coleções de espécies do iNaturalist



Fonte: adaptado de iNaturalist (2023a).

O software utiliza um mecanismo de identificação de espécies próprio, o iNat2017, onde é utilizada visão computacional para gerar sugestões de qual foi a espécie observada pelo usuário. A forma com a qual o modelo utilizado pelo mecanismo funciona não foi especificado. Com isso, o software é acessível não somente aos observadores experientes, como também aos entusiastas da biologia, democratizando o acesso à categorização de espécies e tornando a documentação de biodiversidade mais abrangente (INATURALIST, 2023a).

O processo de identificação de espécies utiliza como base um conjunto de dados contendo milhões de imagens de diferentes espécies, alguns deles mantidos pela própria iniciativa e disponíveis publicamente na plataforma Kaggle. A ferramenta está disponível em três diferentes plataformas: web, Android e iOS. A versão para web foi desenvolvida em JavaScript, HTML, SCSS e Ruby on Rails. Já a versão para Android foi desenvolvida em Java e a para iOS em Objective-C. Todas as plataformas consultam uma API em Express e os dados são armazenados no banco de dados PostgreSQL (INATURALIST, 2023b).

Apesar das sugestões de classificação de imagens de espécies abrangendo diversas espécies com características distintas, o produto não é direcionado para o reconhecimento de serpentes, não garantindo sua confiabilidade no reconhecimento delas. O mesmo ocorre com outras espécies, em que a identificação de

determinadas imagens não é eficiente. Como uma forma de contornar classificações incorretas, após a sugestão realizada pelo software, a própria comunidade oferece curadoria para a confirmação ou correção da sugestão oferecida pela plataforma, garantindo informações confiáveis aos usuários, assim como enriquecimento da base de dados crescente da ferramenta (INATURALIST, 2023a).

2.2 SNAKE SPECIES IDENTIFICATION AND RECOGNITION

Vasmatkar *et al.* (2020) apresentam a criação de um sistema para identificação de espécies de serpentes a partir de suas características visuais, com o objetivo de auxiliar no tratamento e prevenir mortes causadas por mordidas. O sistema concentra-se apenas na identificação de serpentes, o que reduz o escopo de treinamento. O trabalho utilizou 3050 imagens em RGB de 28 espécies de serpentes. A região e espécies a serem identificadas não foram especificados pelos autores.

A arquitetura e fluxo de processamento do sistema desenvolvido segue o modelo tradicional de pré-processamento, treinamento, classificação, validação e verificação de acurácia, como apresentado na Figura 2. Na etapa de pré-processamento o algoritmo GrabCut foi utilizado para remover detalhes do fundo da imagem, realçando as características morfológicas da serpente. Além disso, como o conjunto de dados utilizado possui apenas 3050 imagens, não suficiente para o treinamento de RNAs são utilizadas técnicas de *Data Augmentation* para aumentar o conjunto de dados original, criando novas imagens com variações de rotação, espelhamento horizontal, entre outras (VASMATKAR *et al.*, 2020, p. 1).

Durante a etapa de treinamento, foram utilizados três diferentes modelos de RNA pré treinados, a fim de comparar a acurácia alcançada em cada um deles sendo eles: DenseNet, MobileNetV2 e VGG16 (Figura 2). Todos os três utilizam Redes Neurais Convolucionais, porém com diferentes estruturas de camadas, pesos e funções de ativação. Os resultados foram variados entre os três modelos, o DenseNet obteve o melhor desempenho, alcançando 72% de acurácia, o MobileNetV2 alcançou 58,65% de acurácia e o VGG16, apenas 12,28% (VASMATKAR *et al.*, 2020, p. 4).

Figura 2 – Acurácia dos modelos testados

Model	Epochs	Validation accuracy(%)	Test accuracy(%)
DenseNet	50	78	72
MobileNet	50	62.7	58.65
VGG16	50	17.2	12.28

Fonte: Vasmatkar *et al.* (2020, p. 4).

Já o processo de identificação das imagens foi desenvolvido utilizando a linguagem de programação Python, em conjunto com as bibliotecas OpenCV e PyTorch com suporte à CUDA, uma API desenvolvida pela Nvidia para computação paralela. Para a visualização de métricas, gráficos do treinamento e acurácia dos modelos, foi utilizada a ferramenta TensorBoard Vasmatkar *et al.*, (2020), faz menção a existência de uma interface de interação com o usuário na qual é possível selecionar a imagem a ser analisada, mas a forma de interação e tecnologias utilizadas não estão especificadas no artigo.

2.3 A COMPARATIVE STUDY ON IMAGE-BASED SNAKE IDENTIFICATION USING MACHINE LEARNING

No trabalho desenvolvido por Rajabizadeh e Rezghi (2021) foram aplicados diferentes métodos de aprendizado de máquina e RNA na identificação de seis espécies distintas de serpentes a partir da identificação de suas características físicas. As espécies estudadas são encontradas no Parque Nacional Lar, uma área protegida na província de Mazandaran, no Irã, a fim de entender qual método possui uma melhor acurácia na identificação de serpentes.

Durante o estudo Rajabizadeh e Rezghi (2021) utilizaram Máquina de Vetor Suporte (Support Vector Machine - SVM), K-vizinhos mais próximos (K-Nearest Neighbours - KNN) e Regressão logística em combinação com as abordagens Análise de Componentes Principais (Principal Component Analysis - PCA) e Análise Discriminante para comparar sua acurácia com as RNAs, utilizando as arquiteturas MobileNetV2 e VGG16, duas RNAs de aprendizado profundo, a fim de entender como diferentes técnicas de aprendizado podem ser utilizadas em conjunto para uma maior acurácia na identificação dos animais (RAJABIZADEH; REZGHI, 2021).

Para o conjunto de dados foram utilizadas 594 imagens de serpentes, na qual pelo menos 50% do corpo do animal estava visível. Como o conjunto de imagens não era suficiente para utilizar modelos de aprendizado profundo, a técnica de Aprendizagem por Transferência (Transfer Learning - TL) foi utilizada no processo de treinamento dos modelos utilizados (RAJABIZADEH; REZGHI, 2021).

Para processamento, as imagens de entrada foram redimensionadas para 224*224*3. E, posteriormente, cada imagem foi convertida a um vetor com comprimento de 150.528. E estes vetores foram convertidos em uma matriz com 594 linhas e 150.528 colunas. Após este processamento, as imagens foram particionadas em 80% para treinamento e 20% para testes. A Figura 3 apresenta os resultados alcançados pelos autores utilizando MobileNetV2 e VGG16 nas seis espécies identificadas.

Figura 3 - Resultados de acurácia dos modelos MobileNetV2 e VGG-16

	MobileNetV2			VGG-16		
	Precision	Recall	F1-score	Precision	Recall	F1-score
<i>Gloydus</i>	0.96	0.88	0.92	0.8	0.8	0.8
<i>Hemorrhhois</i>	0.89	0.89	0.89	0.73	0.89	0.8
<i>Montivipera</i>	0.96	0.92	0.94	0.84	0.84	0.84
<i>Natrix</i>	0.82	0.95	0.88	0.75	0.47	0.58
<i>Vipera</i>	1	0.93	0.96	1	0.86	0.92
<i>Telescopus</i>	0.94	1	0.97	0.62	0.81	0.7
Accuracy			0.93			0.78

Fonte: Rajabizadeh e Rezghi (2021).

Conforme a Figura 3 o trabalho de Rajabizadeh e Rezghi (2021) alcançou uma acurácia de 93,16% utilizando RNAMobileNetV2, e uma acurácia de 78% utilizando a RNA VGG16. Quanto ao desenvolvimento do modelo, foi utilizada a linguagem de programação Python, junto com as bibliotecas Scikit-learn e Keras, assim como a ferramenta Google Colab para realizar as análises.

3 PROPOSTA DO PROTÓTIPO

Nesta seção serão apresentados a justificativa para a realização do protótipo proposto, assim como os principais Requisitos Funcionais (RF) e Requisitos não funcionais (RNF) e a metodologia utilizada durante o desenvolvimento do protótipo.

3.1 JUSTIFICATIVA

O Quadro 1 apresenta um comparativo entre os trabalhos correlatos. As linhas representam as características e as colunas, os trabalhos.

Quadro 1 - Comparativo dos trabalhos correlatos

Trabalhos Correlatos	iNaturalist (2023a)	Vasmatkar <i>et al.</i> (2020)	Rajabizadeh e Rezghi (2021)
Características			
Quantidade de espécies de serpentes reconhecidas	605	28	6
Total de imagens utilizadas no treinamento do modelo	114.712 imagens	3050 imagens	594 imagens
Tipo de mídia utilizada	Imagem, vídeo e áudio	Imagem	Imagem
Modelos de aprendizado de máquina utilizados	iNat2017	DenseNet, MobileNetV2 e VGG16	MobileNetV2, VGG16, SVM, KNN
Precisão do modelo	Não apresenta	72%	93,16%
Possui interface para o usuário	Sim	Não	Não

Fonte: elaborado pelo autor.

Conforme apresentado no Quadro 1, os três trabalhos cumprem objetivos similares, mas com algumas diferenças. O iNaturalist (2023a) é o único que se propõe a identificar diversos seres vivos e espécies diferentes, enquanto Vasmatkar *et al.* (2020) e Rajabizadeh e Rezghi (2021) reduzem o foco a apenas espécies de serpentes. Além disso, o iNaturalist (2023a) é o único produto comercial analisado, apesar de surgir de uma iniciativa científica, o que dificulta a compreensão de alguns aspectos do funcionamento interno do sistema.

Ambos os trabalhos de Vasmatkar *et al.* (2020) e Rajabizadeh e Rezghi (2021), focam em identificação de serpentes, porém a quantidade de espécies e imagens utilizadas por cada um é consideravelmente diferente. Vasmatkar *et al.* (2020) propuseram identificar 28 espécies e, para isso, utilizaram 3050 imagens. Rajabizadeh e Rezghi (2021) propuseram identificar 6 diferentes espécies e utilizaram apenas 594 imagens. Apesar dos métodos de ambos serem diferentes, o fato de Rajabizadeh e Rezghi (2021) focarem num número menor de espécies pode

justificar o porquê de precisarem de um número menor de imagens. Ambos utilizaram técnicas de *Data Augmentation* para expandir a quantidade de imagens utilizadas.

Tratando-se dos tipos de dados de entrada utilizados, Vasmatkar *et al.* (2020) e Rajabizadeh e Rezghi (2021) trabalham apenas com imagens, enquanto o iNaturalist (2023a) aceita também vídeo e áudio, porém não fica claro como o processamento dessas outras mídias ocorre no sistema. Vasmatkar *et al.* (2020) e Rajabizadeh e Rezghi (2021) assemelham-se novamente em relação aos modelos de aprendizado de máquina utilizados, em que ambos utilizaram o MobileNetV2 e VGG16. Porém Vasmatkar *et al.* (2020) também utilizaram o DenseNet, enquanto Rajabizadeh e Rezghi (2021) utilizaram o SVM e KNN. iNaturalist (2023a) se diferencia novamente dos demais por utilizar um modelo próprio chamado iNat2017.

Como o iNaturalist (2023a) trata-se de um produto comercial cujo foco não é somente a identificação de espécies de serpentes, o mesmo não evidencia o percentual de acurácia alcançado pelo sistema, porém acredita-se não ser um valor muito elevado por depender de curadoria interna da comunidade para auxiliar na identificação. Vasmatkar *et al.* (2020), por outro lado, alcançaram uma acurácia de 72% na identificação de 28 espécies, enquanto Rajabizadeh e Rezghi (2021) alcançaram acurácia de 93,16% na identificação de 6 espécies. Não é possível afirmar com precisão o que levou à acurácia superior de Rajabizadeh e Rezghi (2021) visto que os métodos utilizados foram diferentes, mas é possível observar que o fato de o treinamento do modelo ser focado em uma quantidade menor de espécies possa ter contribuído para este valor.

A partir das informações apresentadas é possível concluir que, com a tecnologia atual é possível a criação de aplicações capazes de identificar com precisão diversas espécies de serpentes, abrindo a oportunidade para novos estudos em regiões específicas para benefício de comunidades locais. O software iNaturalist (2023a) é capaz de identificar um grande número de espécies, mas depende do auxílio de sua comunidade, enquanto os trabalhos de Rajabizadeh e Rezghi (2021) e Vasmatkar *et al.* (2020) propõem a identificação e um grupo significativamente menor de espécies, mas garantido satisfatória precisão.

O trabalho proposto nasce de uma solicitação do Departamento de Ciências Naturais da FURB com o objetivo de ser expandido e utilizado como ferramenta na conservação, educação e auxílio nos casos de picadas, onde a identificação de serpentes é essencial. Para isso, este trabalho pretende utilizar a pesquisa realizada por Waltrick e Giasson (2021) para identificar as características e chaves taxonômicas das espécies de serpentes do Vale do Itajaí, construindo um modelo de reconhecimento de imagens especializado na identificação dessas características.

3.2 REQUISITOS PRINCIPAIS DO PROBLEMA A SER TRABALHADO

O protótipo proposto deverá:

- a) realizar classificação das espécies a partir de imagens e exibir resultados da classificação das imagens (Requisito Funcional - RF);
- b) extrair características morfológicas das serpentes (RF);
- c) realizar o melhoramento das imagens (ruídos, distorções e problema de iluminação) utilizando técnicas de Processamento de Imagens (RF);
- d) utilizar técnicas de Aprendizado de Máquina a serem definidas nos testes (Requisito Não Funcional – RNF);
- e) ser desenvolvido utilizando a linguagem de programação Python com a biblioteca PyTorch (RNF).

3.3 METODOLOGIA

O protótipo será desenvolvido observando as seguintes etapas:

- a) levantamento bibliográfico: realizar levantamento chaves taxonômicas das espécies de serpentes no Vale do Itajaí, algoritmos de processamento de imagens, visão computacional para classificação de imagens e aprendizado de máquina;
- b) realização da coleta das imagens: a fim de compor a base de dados;
- c) definição de algoritmos para extrair as características físicas das serpentes;
definição de algoritmos para realizar a classificação das serpentes: pesquisar técnicas de aprendizado de máquina para o desenvolvimento do modelo;
- d) classificação das características taxonômicas: detalhar as declarações que descrevem características morfológicas das serpentes a ser identificadas;
- e) implementação do modelo: implementar dos modelos de aprendizado de máquina escolhidos;
- a) testes do modelo: paralelamente à implementação, realizar testes com base nas imagens obtidas para verificar a assertividade do modelo elaborado, bem como realizar a comprovação dos resultados em conjunto com professor especialista.

As etapas serão realizadas nos períodos relacionados no Quadro 2.

Quadro 2 – Cronograma de atividades a serem desenvolvidas

etapas / quinzenas	2024									
	fev.		mar.		abr.		mai.		jun.	
	1	2	1	2	1	2	1	2	1	2
levantamento bibliográfico										
coleta de imagens										
definição de algoritmos para extração de características										
definição de algoritmos para realizar a classificação das serpentes										
classificação de características taxonômicas										
implementação										
testes										

Fonte: elaborado pelo autor.

4 REVISÃO BIBLIOGRÁFICA

Esta seção descreve brevemente os assuntos que fundamentarão o desenvolvimento do protótipo proposto. A seção 4.1 aborda as características e utilização do Reconhecimento de padrões. A seção 4.2 faz a contextualização e da Taxonomia, com enfoque na criação de chaves taxonômicas.

4.1 RECONHECIMENTO DE PADRÕES

Reconhecimento de padrões é uma habilidade que os seres vivos possuem de perceber e diferenciar diferentes tipos de informação, como distinguir entre o som de uma voz e o som de um instrumento musical, ou a capacidade de reconhecer, distinguir e separar numerais de letras e demais caracteres escritos. Os padrões são representados por todas as informações que nos cercam, como cheiros, sons e imagens (GEOFF DOUGHERTY, 2013).

Na computação, o Reconhecimento de Padrões é o campo da inteligência artificial dedicado ao objetivo de replicar essa capacidade dos seres vivos, processando, reconhecendo e identificando padrões em conjuntos de dados, para então utilizá-los para realizar previsões, categorizar informações e aperfeiçoar o processo de tomada de decisões (ANSARI, 2018). O reconhecimento de padrões não é uma técnica particular de aprendizado de máquina, mas sim um conglomerado de algoritmos capazes de cumprir objetivos de diversos escopos, sendo ferramenta para outras áreas da inteligência artificial, como Aprendizado de máquina e Aprendizado profundo.

Devido sua versatilidade, os algoritmos de Reconhecimento de Padrões excedem a capacidade humana por não ser limitado aos sentidos, mas sim podem atuar com base em dados de diferentes mídias, podendo ser utilizado em textos, tabelas, imagens, áudios e vídeos, abrindo portas para a utilização em reconhecimento de fala, identificação de pessoas através da voz, reconhecimento biométrico, reconhecimento de documentos multimídia, diagnóstico médico automático (ANSARI, 2018), e reconhecimento de animais.

4.2 CHAVES TAXONOMICAS

A Taxonomia, desenvolvida por Carolus Linnaeus no século XVIII com a publicação de seu livro *Species Plantarum* em 1753, também conhecida como Taxonomia de Lineu é um estudo da área da biologia que classifica e nomeia os seres vivos a partir de suas características morfológicas, fisiológicas genéticas e reprodutivas. A Taxonomia de Lineu foi aperfeiçoada com o decorrer dos séculos, mas a sua base segue como fundamento da Taxonomia moderna (CASTRO, 2007).

A classificação dos seres vivos ocorre através de características taxonômicas, também conhecidos como Taxóns, sendo eles, em ordem decrescente: Reino (Kingdom), Filo (Phylum), Classe (Class), Ordem (Order), Família (Family), Gênero (Genus) e Espécie (CASTILHO, 2022). Na Figura 4 é possível visualizar a classificação taxonômica assim como a autoria de nomeação da serpente *Micrurus corallinus*, popularmente conhecida como cobra-coral verdadeira.

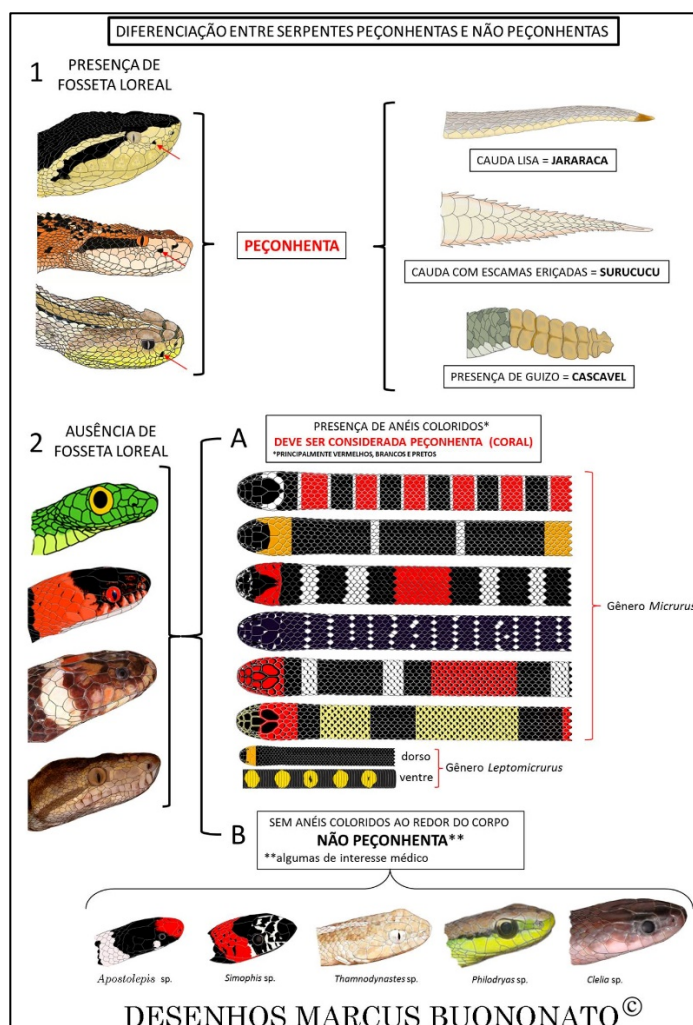
Figura 4 – Taxonomia da serpente *Micrurus corallinus*

Taxonomy		
KINGDOM	PHYLUM	CLASS
Animalia	Chordata	Reptilia
ORDER	FAMILY	GENUS
Squamata	Elapidae	Micrurus
▼ Taxonomy in detail		
SCIENTIFIC NAME	AUTHORITY	
<i>Micrurus corallinus</i>	(Merrem, 1820)	
SYNONYMS	COMMON NAMES	
<i>Elaps corallinus</i> Merrem, 1820	English Painted Coral Snake	

Fonte: Carreira et al. (2014).

Sendo assim as chaves taxonômicas são um dispositivo que usa da taxonomia para gerar chaves específicas para a classificação de espécies. Dada a necessidade de classificação de espécies de serpentes, informações como Reino, Filo, Classe e Ordem são descartados, pois ao tratar-se de serpentes, estas informações já são pré-definidas. As Chaves taxonômicas, neste contexto tem o foco de utilizar características mais específicas dos espécimes para sua classificação. Na identificação de serpentes, as chaves se baseiam principalmente na contagem das fileiras de escamas encontradas ao redor do pescoço, centro do corpo e próximo a cloaca, assim como exame da dentição, escudos cefálicos, número de escamas ventrais e subcaudais e condição das escamas da região dorsal (WALTRICK; GIASSON, 2021). Estas características também podem ser utilizadas para identificar de maneira geral, se uma espécie observada é ou não peçonhenta, e se pode ser manuseada com segurança por um observador, como ilustrado na Figura 5.

Figura 5 - Diferenciação entre serpentes peçonhentas e não peçonhentas



Fonte: Buononato (2015).

REFERÊNCIAS

- ANSARI, S. Pattern Recognition | Introduction - GeeksforGeeks. Disponível em: <<https://www.geeksforgeeks.org/pattern-recognition-introduction/>>. Acesso em: 18 jun. 2023.
- BUONONATO, Marcus. Quadro de identificação rápida das serpentes peçonhentas do Brasil. 02 de nov. 2015. Facebook: Marcus Buononato. Disponível em: <https://www.facebook.com/photo.php?fbid=153995771621689&set=pb.100010338018322.-2207520000.&type=3&locale=pt_BR>. Acesso em: 26 jun. 2023.
- BUNTATAN. Soros. [S.l.]. [2023] Disponível em: <<https://butantan.gov.br/soros>>. Acesso em: 24 abr. 2023.
- CARREIRA, S. et al. IUCN Red List of Threatened Species: *Micrurus corallinus*. Disponível em: <<https://www.iucnredlist.org/species/56040806/56040867>>. Acesso em: 18 jun 2023.
- CASTILHO, Rubens. Classificação dos Seres Vivos. Disponível em: <<https://www.todamateria.com.br/classificacao-dos-seres-vivos/>>.
- CASTRO, Fábio de. Pai da taxonomia. Disponível em: <<https://agencia.fapesp.br/pai-da-taxonomia/8020/>>.
- GEOFF DOUGHERTY. Pattern Recognition and Classification An Introduction. [s.l.] New York, Ny Springer, 2013.
- INATURALIST. Connect with Nature. [S.I.], 2023a. Disponível em: <<https://www.inaturalist.org/>>. Acesso em: 17 abr. 2023.
- INATURALIST. Developers. [S.I.], 2023b. Disponível em: <<https://www.inaturalist.org/pages/developers>>. Acesso em: 17 abr. 2023.
- KNIAZIEVA, Yuliia. Pattern Recognition in Machine Learning. Disponível em: <<https://labyourdata.com/articles/pattern-recognition-in-machine-learning>>. Acesso em: 24 jun. 2023.
- OLIVEIRA, S.N. et al. Ofidismo em Santa Catarina: identificação, prevenção de acidentes e primeiros socorros. Disponível em: <<https://repositorio.ufsc.br/bitstream/handle/123456789/208747/Ofidismo%20em%20Santa%20Catarina.pdf>>. Acesso em: 24 abr. 2023.
- RAJABIZADEH, M.; REZGHI, M. A comparative study on image-based snake identification using machine learning. Scientific Reports, v. 11, n. 1, p. 19142, 27 set. 2021.
- VAN HORN, G. et al. The iNaturalist Species Classification and Detection Dataset. Disponível em: <<https://authors.library.caltech.edu/87114/>>. Acesso em: 24 abr. 2023.
- VASMATKAR, M. et al., "Snake Species Identification and Recognition," 2020 IEEE Bombay Section Signature Conference (IBSSC), Mumbai, India, 2020, pp. 1-5.
- WALTRICK, C. S.; GIASSON, L. O. M. Taxonomic key to the snakes (Squamata: Ophidia) species of the Itajaí Valley, Santa Catarina, Brazil. Papéis Avulsos de Zoologia, v. 61, p. e20216120–e20216120, 18 fev. 2021.
- WILDLIFE AI. Using artificial intelligence to accelerate wildlife conservation. [S.I.]. Disponível em: <<https://www.wildlife.ai/>>. Acesso em: 28 abr. 2023.
- WORLD HEALTH ORGANIZATION. Snakebite envenoming. [S.I.]. Disponível em: <<https://www.who.int/health-topics/snakebite>>. Acesso em: 24 abr. 2023.
- WORLD HEALTH ORGANIZATION. Snakebite envenoming. Disponível em: <<https://www.who.int/news-room/fact-sheets/detail/snakebite-envenoming>>. Acesso em: 24 abr. 2023.